Diagnóstico de Calidad de Datos — Actividad 2

Seminario de Bases de Datos 2026 — ISNSLBV
Equipo: 6 | **Variante:** 6 (Precio de alquiler frente a costo de reposición y recupero de inversión)
Conjunto de trabajo: `df_trabajo` (1 000 películas del catálogo consolidado)

---

1. Contexto y Alcance del Diagnóstico

El presente documento constituye el control previo de calidad de datos (*data profiling*) sobre el conjunto de trabajo extraído desde SQL Server, siguiendo los lineamientos teóricos y las 6 dimensiones de calidad de la **Unidad 5** (*Completitud, Unicidad, Validez, Consistencia, Exactitud y Oportunidad*).

El objetivo es determinar la confiabilidad del conjunto previo al cálculo de métricas derivadas y formalizar las decisiones de transformación o conservación de registros.

---

2. Checklist de Calidad de Datos (Unidad 5)

A continuación se detalla la evaluación sistemática sobre los 8 puntos del recorrido de rutina:

#	Pregunta de Control (Unidad 5)	Hallazgo en los Datos	Decisión / Transformación Propuesta	Fundamento Técnico y de Negocio
1	**¿Volumen y dimensiones esperadas?**	**1 000 filas × 9 columnas.** Coincide con el universo de películas reconciliado contra SQL Server.	**Conservar sin filtrar.**	Se garantiza la totalidad del catálogo; no hay pérdida ni multiplicación de entidades.
2	**¿Tipos de datos correctos?**	Identificadores y contadores en `int64`; importes monetarios en `float64`; textos en `object`/`str`.	**Sin transformación de tipos.**	No hay campos numéricos o fechas infiltrados como texto (`str`).
3	**¿Valores faltantes y criterio adoptado?**	**0 celdas nulas** (`isna().sum() == 0` en todas las columnas).	**Sin imputación.**	La consulta base con `LEFT JOIN` e `ISNULL(..., 0)` resolvió las ausencias en origen.
4	**¿Duplicados por clave de negocio?**	**0 duplicados** sobre `film_id` (`film_id.nunique() == 1000`).	**Sin transformación.**	Cada película del catálogo está representada de forma unívoca.
5	**¿Rangos válidos y reglas de negocio?**	• `rental_rate > 0` (100% cumple) • `replacement_cost >`	**Aceptado.**	Cumplimiento estricto de restricciones del dominio económico del videoclub.

#	Pregunta de Control (Unidad 5)	Hallazgo en los Datos	Decisión / Transformación Propuesta	Fundamento Técnico y de Negocio
		`rental_rate` (100% cumple) • `total_revenue >= 0` (100% cumple) • `replacement_cost` en $[9.99, 29.99]$		
6	**¿Variables categóricas normalizadas?**	`rating` presenta 5 categorías canónicas (`PG-13`, `NC-17`, `R`, `PG`, `G`) sin variantes ortográficas.	**Sin transformación de cadenas.**	No existen espacios sucios, sinónimos ni problemas de mayúsculas/minúsculas.
7	**¿Cardinalidad esperada / Columnas constantes?**	Sin columnas constantes (todas con varianza > 0). `rental_rate` presenta **cardinalidad 3** ($0.99, $2.99, $4.99).	**Segmentación discreta en Actividad 3.**	*Hallazgo crítico:* Invalida el modelado de elasticidad continua; exige comparar 3 estratos de precio.
8	**¿Período temporal adecuado?**	Consolida el histórico completo acumulado de transacciones de alquiler y recaudación.	**Apto para el análisis.**	Cobertura suficiente para evaluar el recupero histórico de la inversión por título.

3. Análisis de Valores Atípicos (Regla IQR de Tukey)

Sobre la métrica principal (`total_revenue`), se calcularon los estadísticos de dispersión:

- Q_1 **(P25):** $33.95 | **Mediana (P50):** $61.85 | Q_3 **(P75):** $93.09 | **IQR:** $59.14
- **Límite Inferior (**$Q_1 - 1.5 \times IQR$**):** $-54.77 * (teórico)*\rightarrow$ Umbral físico: $0.00
- **Límite Superior (**$Q_3 + 1.5 \times IQR$**):** $181.80

Decisiones de Limpieza Justificadas:

1. **Outliers Superiores (11 películas con ingresos** $> \$181.80$**):**
   - **Decisión: NO SE ELIMINAN.**
   - **Fundamento:** Corresponden a los títulos de alta rotación (*blockbusters*, ej. *TELEGRAPH VOYAGE* con $231.73 y 27 alquileres a $4.99). El criterio de Tukey solo identifica candidatos estadísticos; eliminarlos eliminaría los casos comerciales más exitosos y sesgaría negativamente el análisis de rentabilidad.
2. **Películas con Ingreso Cero (42 películas con `total_revenue = $0.0`):**
   - **Decisión: SE CONSERVAN Y SE ETIQUETAN.**
   - **Fundamento:** Coinciden exactamente con las 42 películas sin copias físicas en inventario (`inventory_count = 0`). Su recaudación nula es una consecuencia directa de la falta de stock y no un error de registro. Se segregan para no distorsionar el análisis de rotación de copias activas.

4. Hallazgos Específicos de la Variante 6 y Réplica en Motor

1. **Estructura Discreta de Precios:**
   `rental_rate` se distribuye de forma casi uniforme en solo 3 escalones: $0.99 (34.1%), $2.99 (32.3%) y $4.99 (33.6%). Metodológicamente, esto impide calcular una función de elasticidad-precio continua ($\epsilon = \frac{\%\Delta Q}{\%\Delta P}$), orientando la Actividad 3 hacia el análisis comparativo entre los tres grupos tarifarios.
2. **Consistencia Motor SQL Server vs. Pandas (Exactitud):**
   La réplica de controles de agregación en T-SQL arrojó una **coincidencia del 100%** frente al cliente Pandas (distribución de tarifas y conteo de películas sin ingreso = 42), validando la integridad del mapeo y la extracción.

---

5. Síntesis y Matriz de Transformaciones

- **Registros descartados: 0 filas (0%)**.
- **Registros imputados: 0 filas (0%)**.
- **Transformaciones a ejecutar en Actividad 3:**
  1. Cálculo vectorizado de métricas derivadas (ratio de recupero, break-even de alquileres e ingresos netos).
  2. Flag de segmentación para películas sin inventario (`sin_stock = True`).